

REPORT-TENTATIVAS-CODEX

Chamadas de API do Codex no Coding_Machine

Pergunta: quantas chamadas de API o motor autônomo gastou por pacote do backlog, em que tentativa cada uma aconteceu e com que modelo.
Fonte: .autodev/state.db , tabela `attempts` (o próprio motor grava uma linha por invocação). **Janela:** 27/09/2026 02:03 a 28/09/2026 21:56 — DEVFACTORY-001, 002 e 004 (a 003 foi planejada e nunca executada). **Data do relatório:** 28/09/2026. **Total no período: 94 chamadas do Codex**, 48 delas aprovadas (revisão + integração).


Avisos

- Chamada não é custo.** Cada linha conta **uma invocação** do agente; o motor não registra tokens, então este relatório mede chamadas, não gasto.
- A sprint 001 não é comparável.** Dos seus 15 pacotes, 14 são **registro retroativo** (agente `retroativo` , inserido em 27/09 02:03 para reconstruir o histórico) — **não são chamadas de API**. Só o T15 tem uma chamada real, e sem modelo registrado. É por isso que 14 colunas da sprint 001 estão vazias.
- A sprint 003 não aparece no gráfico:** 7 pacotes planejados, nenhum executado.
- A sprint 004 está em andamento** (4 de 4 pacotes já com chamadas; a P03 está aguardando cota do Codex) — os números dela ainda vão mudar.
- “Nª tentativa” não é o degrau da escada de modelos — são dois contadores.** O número nas tabelas é a **chamada** (`attempt` , sequência do banco, sempre `max+1`); o modelo vem do **contador da task** (`tentativas`), pelo mapa `1ª→luna/low ... 5ª→astra/low` . Quando o contador é reiniciado (rearme por dependência integrada, reabertura por defeito de contrato) ele **volta ao degrau barato** enquanto a numeração da chamada continua — é por isso que existe `luna/low` numa 7ª chamada. O degrau mede “quantas vezes chamou”, não “quão forte era o modelo”. Nas falhas de infraestrutura (`CODEX_QUOTA` , `NETWORK_ERROR` , `ENVIRONMENT_ERROR` ...), a política declara `classes_sem_escalonamento` — mas **essa lista não chega à escolha do modelo**: o orquestrador usa o mapa do contador e ignora o tier da decisão. Na prática, espera de cota escalona como qualquer falha. É um defeito de fiação, não uma intenção.
- A partir da 5ª chamada o mapa satura no topo** (`min(tentativa, 5) → astra/low`): degraus 5 a 15 repetem o mesmo modelo. No período isso **não** virou desperdício: são 8 chamadas no topo (8.5%) contra 45 no degrau mais barato (47.9%) — a cauda é curta porque a maioria dos pacotes aprovou antes do 5º degrau (tabela 3).
- 3 combinação(ões) fora da escada declarada:** (nenhum)/(nenhum) , `gpt-5.6-luna/medium` , `gpt-5.6-terra/medium` . As chamadas `luna/medium` e `terra/medium` aconteceram em 27/09 entre 03:13 e 04:07, **antes** de a escada ser padronizada naquele mesmo dia — não são desvio de política.
- A numeração por pacote tem buracos.** Rearme por dependência integrada e reabertura por defeito de contrato removem/renomeiam tentativas, então 4 pacote(s) (P02 (sprint 002), P03 (sprint 002), P09 (sprint 002), P01 (sprint 004)) têm sequência descontínua — marcados com ▲ na tabela 1. Consequência para a leitura: o degrau 1 pode se repetir na história de um mesmo pacote, e “15 primeiras tentativas para 15 pacotes” é coincidência, não regra.

O que os números dizem

- 94 chamadas do Codex** em 15 pacotes com execução registrada. A mediana é de 6 chamadas por pacote e a média 6.3.
- 16.0% das chamadas são de 1ª tentativa** e 28.7% acontecem até a 2ª. Metade do gasto (4ª tentativa em diante) está na cauda: são poucos pacotes que consumiram a escada inteira.
- 3 pacote(s) resolveram com uma única chamada:** T15 (sprint 001), P01 (sprint 002), P02 (sprint 004).
- Os campeões de gasto:** P02 (sprint 002, 14 chamadas), P04 (sprint 004, 10 chamadas), P03 (sprint 002, 9 chamadas). Os dois são casos conhecidos: a P02 da sprint 2 pedia reescrita de contrato de teste (o mesmo arquivo para tasks diferentes) e a P04 da sprint 4 gastou a escada consertando o próprio comando de teste — 10 tentativas, das quais o defeito era meu, não do agente (decisão D-23).
- A cauda direita do gráfico 1 é o sintoma mais caro do período:** 5 chamadas em degraus 11 a 15, todas em pacotes que só destravaram quando o **defeito de motor** foi corrigido (D-19, D-24, D-25) — nenhuma delas é “o modelo errado tentando mais”.
- 27 das 94 chamadas (28.7%) foram gastas por defeito do nosso teste/plano**, e 8 (8.5%) por infraestrutura (cota/crash). Descontadas, sobram **59 chamadas (62.8%)** atribuíveis ao trabalho do modelo — o denominador honesto para comparar modelos (seção “Descontando”).
- Onde a escada se paga (tabela 3):** 2 pacote(s) aprovaram até a 3ª chamada; 3 na 4ª–5ª; 9 da 6ª em diante. O degrau caro (`astra/low`) assinou 4 aprovação(ões) — sempre em pacote que carregava, junto, defeito de contrato nosso.

Gráfico 1 — chamadas por pacote, empilhadas pela tentativa



Cada coluna é um pacote; a altura é quantas vezes o Codex foi chamado nele; a cor diz **em que altura da escada** a chamada aconteceu (verde = cedo, vermelho = fim da escada). Total: 94 chamadas.

Tabela 1 — por pacote

chamadas é o custo; aprov./reprov./s/aval. são as **avaliações do modelo aprovador** naquele pacote (aprovado / reprovado / chamadas que nem chegaram a ser avaliadas); aprovada na diz **em que chamada** (e com que modelo) a aprovação saiu; **infra** e **culpa teste/plano** separam o que **não era do modelo** (cota/crash e defeito de teste/plano, atribuição curada descrita abaixo); **do modelo** é o que sobra.

retrab. bruto = **reprovações do aprovador ÷ aprovações do aprovador** (quanto a escada cobrou de volta por aprovação entregue); retrab. ajust. desconta as reprovações que foram culpa do **nosso teste/plano** — nunca as do codificador. Pacote sem aprovação nenhuma fica —. No total: **24 reprovações ÷ 47 aprovações = 51.1% bruto e 44.7% ajustado** (a escada cobrou 3 reprovações que eram defeito do NOSSO teste/plano). Se o denominador for *chamadas avaliadas* em vez de aprovações — **reprov ÷ (aprov+reprov)** — os mesmos números ficam 33.8% e 30.9%.

sprint	pacote	chamadas	aprov./reprov./s/aval.	chamadas (1ª-última)	aprovada na	infra	culpa teste/plano	do modelo	retrab. bruto	retrab. ajust.	modelos usados
001	T15	1	0/0/1	1ª-1ª	—	0	0	1	—	—	(nenhum)/(nenhum)
002	P01	1	1/0/0	1ª-1ª	1ª (gpt-5.6-luna/low)	0	0	1	0%	0%	gpt-5.6-luna/low
002	P02	14	5/5/4	1ª-15ª ▲	14ª (gpt-5.6-sol/low)	3	5	6	100%	100%	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
002	P03	9	6/2/1	1ª-10ª ▲	9ª (gpt-5.6-sol/medium)	1	5	3	33%	33%	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium
002	P04	9	6/2/1	1ª-9ª	9ª (gpt-6-astra/low)	1	0	8	33%	33%	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
002	P05	6	4/2/0	1ª-6ª	6ª (gpt-5.6-sol/low)	0	0	6	50%	50%	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low, gpt-5.6-terra/medium
002	P06	7	5/1/1	1ª-7ª	7ª (gpt-6-astra/low)	1	0	6	20%	20%	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
002	P07	6	4/1/1	1ª-6ª	6ª (gpt-5.6-sol/low)	0	0	6	25%	25%	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low, gpt-5.6-terra/medium
002	P08	4	4/0/0	1ª-4ª	4ª (gpt-5.6-sol/low)	0	0	4	0%	0%	gpt-5.6-luna/low, gpt-5.6-sol/low
002	P09	9	4/3/2	1ª-10ª ▲	9ª (gpt-6-astra/low)	1	7	1	75%	0%	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
002	P10	5	4/1/0	1ª-5ª	5ª (gpt-5.6-sol/low)	0	0	5	25%	25%	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low
004	P01	8	1/2/5	1ª-9ª ▲	8ª (gpt-5.6-sol/low)	0	5	3	200%	200%	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-5.6-terra/low, gpt-6-astra/low
004	P02	1	1/0/0	1ª-1ª	1ª (gpt-5.6-luna/low)	0	0	1	0%	0%	gpt-5.6-luna/low
004	P03	4	1/2/1	1ª-4ª	4ª (gpt-5.6-sol/medium)	1	0	3	200%	200%	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-5.6-terra/low

sprint	pacote	chamadas	aprov./reprov./s/aval.	chamadas (1ª–última)	aprovada na	infra	culpa teste/plano	do modelo	retrab. bruto	retrab. ajust.	modelos usados
004	P04	10	1/3/6	1ª–10ª	10ª (gpt-6-astra/low)	0	5	5	300%	300%	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-5.6-terra/low, gpt-6-astra/low

Tabela 3 — em que chamada a aprovação veio

O valor marginal da escada: onde os pacotes **efetivamente** destravaram. É esta tabela que decide se a 4ª/5ª posição da escada se paga.

aprovada na	pacotes	quais	modelo que aprovou
1ª chamada	2	P01 (002), P02 (004)	gpt-5.6-luna/low
2ª–3ª	0	—	—
4ª–5ª	3	P08 (002), P10 (002), P03 (004)	gpt-5.6-sol/low, gpt-5.6-sol/medium
6ª–10ª	8	P03 (002), P04 (002), P05 (002), P06 (002), P07 (002), P09 (002), P01 (004), P04 (004)	gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
11ª–15ª	1	P02 (002)	gpt-5.6-sol/low


Descontando o que não era do modelo

A classe da falha o motor grava; **de quem era a culpa, não**. As janelas abaixo foram atribuídas à mão, olhando os logs e as decisões — e por isso aparecem em coluna separada, nunca no lugar do dado bruto. Sem esse desconto, qualquer comparação entre modelos cobra do agente o defeito do nosso teste.

sprint	pacote	chamadas	culpa teste/plano	do modelo	decisão que descreve
002	P09	9	7	1	D-16: idem (aprovado e feito no laço de integração) (chamadas 1–3); D-19: contrato de preservação impossível (chamadas 4–8)
002	P02	14	5	6	D-16: duas tasks donas do mesmo arquivo de teste (chamadas 1–5)
002	P03	9	5	3	D-16: idem (chamadas 1–5)
004	P01	8	5	3	D-23: critério mandava .venv dentro do worktree (chamadas 1–6)
004	P04	10	5	5	D-23: idem (chamadas 1–5)

No total: **27 chamadas (28.7%)** foram gastas por defeito do nosso teste/plano e **8 (8.5%) por infraestrutura** (cota, crash). Sobram **59 chamadas (62.8%)** atribuíveis ao trabalho do modelo — esse é o único denominador honesto para comparar modelos.

Gráfico 2 — distribuição por número de tentativa



Percentual das chamadas por número de tentativa, com o modelo dominante de cada degrau

Tabela 2 — por degrau

tentativa	chamadas	% das chamadas	% acumulado	aprovadas	modelos usados
1ª	15	16.0%	16.0%	7	gpt-5.6-luna/low (14), (nenhum)/(nenhum) (1)
2ª	12	12.8%	28.7%	7	gpt-5.6-luna/medium (5), gpt-5.6-luna/low (4), gpt-5.6-terra/low (3)
3ª	12	12.8%	41.5%	9	gpt-5.6-luna/low (7), gpt-5.6-sol/low (3), gpt-5.6-terra/medium (2)
4ª	11	11.7%	53.2%	9	gpt-5.6-luna/low (7), gpt-5.6-sol/low (2), gpt-5.6-sol/medium (2)
5ª	10	10.6%	63.8%	6	gpt-5.6-luna/low (5), gpt-5.6-sol/low (2), gpt-5.6-sol/medium (2), gpt-6-astra/low (1)
6ª	9	9.6%	73.4%	2	gpt-5.6-sol/low (4), gpt-5.6-luna/low (2), gpt-6-astra/low (2), gpt-5.6-sol/medium (1)
7ª	6	6.4%	79.8%	1	gpt-5.6-sol/low (3), gpt-6-astra/low (1), gpt-5.6-luna/low (1), gpt-5.6-terra/low (1)
8ª	5	5.3%	85.1%	1	gpt-5.6-sol/low (2), gpt-5.6-sol/medium (2), gpt-5.6-terra/low (1)
9ª	5	5.3%	90.4%	2	gpt-5.6-sol/low (3), gpt-6-astra/low (1), gpt-5.6-sol/medium (1)
10ª	4	4.3%	94.7%	3	gpt-6-astra/low (2), gpt-5.6-sol/low (1), gpt-5.6-sol/medium (1)
11ª	1	1.1%	95.7%	0	gpt-5.6-sol/medium (1)
12ª	1	1.1%	96.8%	0	gpt-6-astra/low (1)
13ª	1	1.1%	97.9%	0	gpt-5.6-sol/low (1)
14ª	1	1.1%	98.9%	0	gpt-5.6-sol/medium (1)
15ª	1	1.1%	100.0%	1	gpt-5.6-sol/low (1)

A escada declarada × o que aconteceu

Escada de implementação no `models.yaml` (tentativa → modelo): 1ª luna/low · 2ª terra/low · 3ª sol/low · 4ª sol/medium · 5ª astra/low .

O que a base mostra é diferente em pontos importantes, e por motivos conhecidos:

- 1. **Contador da task ≠ número da chamada** (aviso 5) — a explicação principal. O contador reinicia no rearme/reabertura e volta ao degrau barato enquanto a chamada continua sendo numerada. Isso é **desejado**: nos rearames de 28/09 a P01 e a P04 voltaram ao degrau 1 e subiram de novo — gastaram barato até acertar, em vez de continuar no topo.
- 2. **Falha de infraestrutura hoje ESCALONA** (aviso 5): a lista `classes_sem_escalamento` existe na política, mas o orquestrador escolhe o modelo pelo contador e ignora o tier da decisão. A intenção declarada (“espera de cota não gasta degrau”) **não está fiada no código** — defeito registrado como pendência.
- 3. **Saturação depois da 5ª** (aviso 6): o mapa tem 5 entradas, então degraus ≥5 usam `astra/low`. No período o topo aparece em 8 das 94 chamadas.
- 4. **Buracos na numeração** (aviso 8) e **5 chamadas anteriores à padronização** da própria escada (aviso 7).

A pergunta de política que fica: escalar por **número** (é o que existe) ou por **causa** — só escalar quando o teste do código falhar ou o revisor reprovar, e reiniciar no degrau barato quando a falha foi de infraestrutura/harness. A tabela 3 dá a medida de que lado pesa: os pacotes que aprovaram até a 3ª chamada mostram quanto trabalho se resolve sem sair do degrau mais barato.

Arquivos gerados e proveniência

arquivo	o que é
REPORT-TENTATIVAS-CODEX.md	este relatório
report/histograma-tentativas.png	gráfico 1
report/distribuicao-tentativas.png	gráfico 2
report/dados.json	agregação crua usada no texto e nos gráficos
report/gerar_relatorio_tentativas.py	gera os três a partir de <code>.autodev/state.db</code>
report/relatorio-tentativas.html / .pdf	HTML autocontido e PDF A4

Reproduzir:

```
cd ~/Code/Coding_Machine
~/hermes/cache/scratch/venv_report/bin/python report/gerar_relatorio_tentativas.py
pandoc REPORT-TENTATIVAS-CODEX.md -o report/relatorio-tentativas.html --standalone \
  --embed-resources --resource-path=.:report --css=report/estilo-relatorio.css \
  --metadata lang=pt-BR
chromium --headless=new --disable-gpu --no-sandbox --user-data-dir=/tmp/chrome-pdf \
  --virtual-time-budget=30000 --no-pdf-header-footer \
  --print-to-pdf="$PWD/report/relatorio-tentativas.pdf" \
  "file://$PWD/report/relatorio-tentativas.html"
```

O venv `~/hermes/cache/scratch/venv_report` existe só para o `matplotlib` (o venv do projeto não tem gráficos) e é descartável: `uv venv + uv pip install matplotlib`.