

Chamadas de API do Codex no Coding_Machine

Pergunta: quantas chamadas de API o motor autônomo gastou por pacote do backlog, em que tentativa cada uma aconteceu e com que modelo.
Fonte: `.autodev/state.db`, tabela `attempts` (o próprio motor grava uma linha por invocação). **Janela:** 27/09/2026 02:03 a 28/09/2026 00:11 — DEVFACTORY-001, 002, 003 e 004 (a 003 entrou em execução em 28/09 22:58: até aqui só a P01 dela tem chamadas). **Data do relatório:** 29/09/2026.
Total no período: 103 chamadas do Codex, 49 delas aprovadas (revisão + integração).


Avisos

- Chamada não é custo.** Cada linha conta uma invocação do agente; o motor não registra tokens, então este relatório mede chamadas, não gasto.
- A sprint 001 não é comparável.** Dos seus 15 pacotes, 14 são **registro retroativo** (agente `retroativo`, inserido em 27/09 02:03 para reconstruir o histórico) — **não são chamadas de API**. Só o T15 tem uma chamada real, e sem modelo registrado. É por isso que 14 colunas da sprint 001 estão vazias.
- A sprint 003 aparece com 1 de 7 pacotes:** ela entrou em execução em 28/09 22:58 e a P01 fechou em 6 chamadas (aprovada no 5º degrau, `astra/low`); as outras 6 ainda não rodaram.
- A sprint 004 está fechada** (4/4 integradas em 28/09) — os números dela não mudam mais.
- “Nª tentativa” não é o degrau da escada de modelos — são dois contadores.** O número nas tabelas é a **chamada** (`attempt`, sequência do banco, sempre `max+1`); o modelo vem do **contador da task** (`tentativas`), pelo mapa `1ª→luna/low ... 5ª→astra/low`. Quando o contador é reiniciado (rearme por dependência integrada, reabertura por defeito de contrato) ele **volta ao degrau barato** enquanto a numeração da chamada continua — é por isso que existe `luna/low` numa 7ª chamada. O degrau mede “quantas vezes chamou”, não “quão forte era o modelo”. Nas falhas de infraestrutura (`CODEX_QUOTA`, `NETWORK_ERROR`, `ENVIRONMENT_ERROR` ...), a política declara `classes_sem_escalonamento` — mas **essa lista não chega à escolha do modelo**: o orquestrador usa o mapa do contador e ignora o tier da decisão. Na prática, espera de cota escalona como qualquer falha. É um defeito de fiação, não uma intenção.
- A partir da 5ª chamada o mapa satura no topo** (`min(tentativa, 5) → astra/low`): degraus 5 a 15 repetem o mesmo modelo. No período isso **não** virou desperdício: são 10 chamadas no topo (9.7%) contra 47 no degrau mais barato (45.6%) — a cauda é curta porque a maioria dos pacotes aprovou antes do 5º degrau (tabela 3).
- 3 combinação(ões) fora da escada declarada:** `(nenhum)/(nenhum)`, `gpt-5.6-luna/medium`, `gpt-5.6-terra/medium`. As chamadas `luna/medium` e `terra/medium` aconteceram em 27/09 entre 03:13 e 04:07, **antes** de a escada ser padronizada naquele mesmo dia — não são desvio de política.
- A numeração por pacote tem buracos.** Rearme por dependência integrada e reabertura por defeito de contrato removem/renomeiam tentativas, então 4 pacote(s) (P02 (sprint 002), P03 (sprint 002), P09 (sprint 002), P01 (sprint 004)) têm sequência descontínua — marcados com ▲ na tabela 1. Consequência para a leitura: o degrau 1 pode se repetir na história de um mesmo pacote, e “15 primeiras tentativas para 15 pacotes” é coincidência, não regra.

O que os números dizem

- 103 chamadas do Codex** em 17 pacotes com execução registrada. A mediana é de 6 chamadas por pacote e a média 6.1.
- 16.5% das chamadas são de 1ª tentativa** e 30.1% acontecem até a 2ª. Metade do gasto (4ª tentativa em diante) está na cauda: são poucos pacotes que consumiram a escada inteira.
- 3 pacote(s) resolveram com uma única chamada:** T15 (sprint 001), P01 (sprint 002), P02 (sprint 004).
- Os campeões de gasto:** P02 (sprint 002, 14 chamadas), P04 (sprint 004, 10 chamadas), P03 (sprint 002, 9 chamadas). Os dois são casos conhecidos: a P02 da sprint 2 pedia reescrita de contrato de teste (o mesmo arquivo para tasks diferentes) e a P04 da sprint 4 gastou a escada consertando o próprio comando de teste — 10 tentativas, das quais o defeito era meu, não do agente (decisão D-23).
- A cauda direita do gráfico 1 é o sintoma mais caro do período:** 5 chamadas em degraus 11 a 15, todas em pacotes que só destravaram quando o **defeito de motor** foi corrigido (D-19, D-24, D-25) — nenhuma delas é “o modelo errado tentando mais”.
- 27 das 103 chamadas (26.2%) foram gastas por defeito do nosso teste/plano**, e 8 (7.8%) por infraestrutura (cota/crash). Descontadas, sobram **68 chamadas (66.0%)** atribuíveis ao trabalho do modelo — o denominador honesto para comparar modelos (seção “Descontando”).
- Onde a escada se paga (tabela 3):** 2 pacote(s) aprovaram até a 3ª chamada; 3 na 4ª–5ª; 10 da 6ª em diante. O degrau caro (`astra/low`) assinou 5 aprovação(ões) — sempre em pacote que carregava, junto, defeito de contrato nosso.

Gráfico 1 — chamadas por pacote, empilhadas pela tentativa



Chamadas de API do Codex por pacote do backlog, empilhadas pelo número da tentativa

Cada coluna é um pacote; a altura é quantas vezes o Codex foi chamado nele; a cor diz **em que altura da escada** a chamada aconteceu (verde = cedo, vermelho = fim da escada). Total: 103 chamadas.

Tabela 1 — por pacote

chamadas é o custo; aprov./reprov./s/aval. são as **avaliações do modelo aprovador** naquele pacote (aprovado / reprovado / chamadas que nem chegaram a ser avaliadas); aprovada na diz **em que chamada** (e com que modelo) a aprovação saiu; infra e culpa teste/plano separam o que **não era do modelo** (cota/crash e defeito de teste/plano, atribuição curada descrita abaixo); do modelo é o que sobra.

retrab. bruto = **reprovações do aprovador ÷ aprovações do aprovador**, em múltiplo: 2x significa duas reprovações para cada aprovação entregue (não é porcentagem de nada — pode passar de 1x, e é por isso que vai em x e não em %); retrab. ajust. desconta as reprovações que foram culpa do **nosso teste/plano** — nunca as do codificador. Pacote sem aprovação nenhuma fica —. No total: **31 reprovações ÷ 48 aprovações = 0,6x bruto e 0,6x ajustado** (a escada cobrou 3 reprovações que eram defeito do NOSSO teste/plano). Se o denominador for **chamadas avaliadas** em vez de aprovações — $\text{reprov} \div (\text{aprov} + \text{reprov})$, aí sim uma fatia — os mesmos números ficam 39.2% e 36.8%.

sprint	pacote	chamadas	aprov./reprov./s/aval.	chamadas (1ª-última)	aprovada na	infra	culpa teste/plano	do modelo	retrab. bruto	retrab. ajust.	modelos usados
001	T15	1	0/0/1	1ª-1ª	—	0	0	1	—	—	(nenhum)/(nenhum)
002	P01	1	1/0/0	1ª-1ª	1ª (gpt-5.6-luna/low)	0	0	1	0x	0x	gpt-5.6-luna/low
002	P02	14	5/5/4	1ª-15ª ▲	14ª (gpt-5.6-sol/low)	3	5	6	1x	1x	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
002	P03	9	6/2/1	1ª-10ª ▲	9ª (gpt-5.6-sol/medium)	1	5	3	0,3x	0,3x	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium
002	P04	9	6/2/1	1ª-9ª	9ª (gpt-6-astra/low)	1	0	8	0,3x	0,3x	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
002	P05	6	4/2/0	1ª-6ª	6ª (gpt-5.6-sol/low)	0	0	6	0,5x	0,5x	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low, gpt-5.6-terra/medium
002	P06	7	5/1/1	1ª-7ª	7ª (gpt-6-astra/low)	1	0	6	0,2x	0,2x	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
002	P07	6	4/1/1	1ª-6ª	6ª (gpt-5.6-sol/low)	0	0	6	0,2x	0,2x	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low, gpt-5.6-terra/medium
002	P08	4	4/0/0	1ª-4ª	4ª (gpt-5.6-sol/low)	0	0	4	0x	0x	gpt-5.6-luna/low, gpt-5.6-sol/low
002	P09	9	4/3/2	1ª-10ª ▲	9ª (gpt-6-astra/low)	1	7	1	0,8x	0x	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
002	P10	5	4/1/0	1ª-5ª	5ª (gpt-5.6-sol/low)	0	0	5	0,2x	0,2x	gpt-5.6-luna/low, gpt-5.6-luna/medium, gpt-5.6-sol/low
003	P01	6	1/5/0	1ª-6ª	6ª (gpt-6-astra/low)	0	0	6	5x	5x	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-5.6-terra/low, gpt-6-astra/low
003	P02	3	0/2/1	1ª-3ª	—	0	0	3	—	—	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-terra/low
004	P01	8	1/2/5	1ª-9ª ▲	8ª (gpt-5.6-sol/low)	0	5	3	2x	2x	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-5.6-terra/low, gpt-6-astra/low

sprint	pacote	chamadas	aprov./reprov./s/aval.	chamadas (1ª–última)	aprovada na	infra	culpa teste/plano	do modelo	retrab. bruto	retrab. ajust.	modelos usados
004	P02	1	1/0/0	1ª–1ª	1ª (gpt-5.6-luna/low)	0	0	1	0x	0x	gpt-5.6-luna/low
004	P03	4	1/2/1	1ª–4ª	4ª (gpt-5.6-sol/medium)	1	0	3	2x	2x	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-5.6-terra/low
004	P04	10	1/3/6	1ª–10ª	10ª (gpt-6-astra/low)	0	5	5	3x	3x	gpt-5.6-luna/low, gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-5.6-terra/low, gpt-6-astra/low

Tabela 3 — em que chamada a aprovação veio

O valor marginal da escada: onde os pacotes **efetivamente** destravaram. É esta tabela que decide se a 4ª/5ª posição da escada se paga.

aprovada na	pacotes	quais	modelo que aprovou
1ª chamada	2	P01 (002), P02 (004)	gpt-5.6-luna/low
2ª–3ª	0	—	—
4ª–5ª	3	P08 (002), P10 (002), P03 (004)	gpt-5.6-sol/low, gpt-5.6-sol/medium
6ª–10ª	9	P03 (002), P04 (002), P05 (002), P06 (002), P07 (002), P09 (002), P01 (003), P01 (004), P04 (004)	gpt-5.6-sol/low, gpt-5.6-sol/medium, gpt-6-astra/low
11ª–15ª	1	P02 (002)	gpt-5.6-sol/low


Descontando o que não era do modelo

A classe da falha o motor grava; **de quem era a culpa, não**. As janelas abaixo foram atribuídas à mão, olhando os logs e as decisões — e por isso aparecem em coluna separada, nunca no lugar do dado bruto. Sem esse desconto, qualquer comparação entre modelos cobra do agente o defeito do nosso teste.

sprint	pacote	chamadas	culpa teste/plano	do modelo	decisão que descreve
002	P09	9	7	1	D-16: idem (aprovado e refeito no laço de integração) (chamadas 1–3); D-19: contrato de preservação impossível (chamadas 4–8)
002	P02	14	5	6	D-16: duas tasks donas do mesmo arquivo de teste (chamadas 1–5)
002	P03	9	5	3	D-16: idem (chamadas 1–5)
004	P01	8	5	3	D-23: critério mandava .venv dentro do worktree (chamadas 1–6)
004	P04	10	5	5	D-23: idem (chamadas 1–5)

No total: **27 chamadas (26.2%)** foram gastas por defeito do nosso teste/plano e **8 (7.8%) por infraestrutura** (cota, crash). Sobram **68 chamadas (66.0%)** atribuíveis ao trabalho do modelo — esse é o único denominador honesto para comparar modelos.

Gráfico 2 — distribuição por número de tentativa



Percentual das chamadas por número de tentativa, com o modelo dominante de cada degrau

Tabela 2 — por degrau

tentativa	chamadas	% das chamadas	% acumulado	aprovadas	modelos usados
1 ^a	17	16.5%	16.5%	7	gpt-5.6-luna/low (16), (nenhum)/(nenhum) (1)
2 ^a	14	13.6%	30.1%	7	gpt-5.6-luna/medium (5), gpt-5.6-terra/low (5), gpt-5.6-luna/low (4)
3 ^a	14	13.6%	43.7%	9	gpt-5.6-luna/low (7), gpt-5.6-sol/low (5), gpt-5.6-terra/medium (2)
4 ^a	12	11.7%	55.3%	9	gpt-5.6-luna/low (7), gpt-5.6-sol/medium (3), gpt-5.6-sol/low (2)
5 ^a	11	10.7%	66.0%	6	gpt-5.6-luna/low (5), gpt-5.6-sol/low (2), gpt-5.6-sol/medium (2), gpt-6-astra/low (2)
6 ^a	10	9.7%	75.7%	3	gpt-5.6-sol/low (4), gpt-6-astra/low (3), gpt-5.6-luna/low (2), gpt-5.6-sol/medium (1)
7 ^a	6	5.8%	81.6%	1	gpt-5.6-sol/low (3), gpt-6-astra/low (1), gpt-5.6-luna/low (1), gpt-5.6-terra/low (1)
8 ^a	5	4.9%	86.4%	1	gpt-5.6-sol/low (2), gpt-5.6-sol/medium (2), gpt-5.6-terra/low (1)
9 ^a	5	4.9%	91.3%	2	gpt-5.6-sol/low (3), gpt-6-astra/low (1), gpt-5.6-sol/medium (1)
10 ^a	4	3.9%	95.1%	3	gpt-6-astra/low (2), gpt-5.6-sol/low (1), gpt-5.6-sol/medium (1)
11 ^a	1	1.0%	96.1%	0	gpt-5.6-sol/medium (1)
12 ^a	1	1.0%	97.1%	0	gpt-6-astra/low (1)
13 ^a	1	1.0%	98.1%	0	gpt-5.6-sol/low (1)
14 ^a	1	1.0%	99.0%	0	gpt-5.6-sol/medium (1)
15 ^a	1	1.0%	100.0%	1	gpt-5.6-sol/low (1)

A escada declarada × o que aconteceu

Escada de implementação no `models.yaml` (tentativa → modelo): 1^a luna/low · 2^a terra/low · 3^a sol/low · 4^a sol/medium · 5^a astra/low .


O que a base mostra é diferente em pontos importantes, e por motivos conhecidos:

1. **Contador da task ≠ número da chamada** (aviso 5) — a explicação principal. O contador reinicia no rearme/reabertura e volta ao degrau barato enquanto a chamada continua sendo numerada. Isso é **desejado**: nos rearames de 28/09 a P01 e a P04 voltaram ao degrau 1 e subiram de novo — gastaram barato até acertar, em vez de continuar no topo.
2. **Falha de infraestrutura hoje ESCALONA** (aviso 5): a lista `classes_sem_escalonamento` existe na política, mas o orquestrador escolhe o modelo pelo contador e ignora o tier da decisão. A intenção declarada (“espera de cota não gasta degrau”) **não está fiada no código** — defeito registrado como pendência.
3. **Saturação depois da 5ª** (aviso 6): o mapa tem 5 entradas, então degraus ≥5 usam `astra/low`. No período o topo aparece em 10 das 103 chamadas.
4. **Buracos na numeração** (aviso 8) e **5 chamadas anteriores à padronização** da própria escada (aviso 7).

A pergunta de política que fica: escalonar por **número** (é o que existe) ou por **causa** — só escalar quando o teste do código falhar ou o revisor reprovar, e reiniciar no degrau barato quando a falha foi de infraestrutura/harness. A tabela 3 dá a medida de que lado pesa: os pacotes que aprovaram até a 3ª chamada mostram quanto trabalho se resolve sem sair do degrau mais barato.

Gráfico 3 — custo por pacote: esperado × retrabalho

Coding_Machine — custo por pacote: esperado (1ª chamada) × retrabalho
assinatura US\$ 20/mês · total estimado US\$ 2.25 em 103 chamadas do Codex: esperado US\$ 0.35 (16%) · retrabalho US\$ 1.90 (84%, ×6.4 sobre o esperado)



Custo por pacote: azul = esperado (1ª chamada), vermelho = retrabalho; sólido = token medido pelo motor, hachurado = estimativa

Duas leituras na mesma barra. A **cor** diz se o dinheiro era **esperado** (a 1ª chamada do pacote, a tentativa de acertar de primeira) ou **retrabalho** (da 2ª em diante: cada chamada extra existe porque a anterior não passou). O **padrão** diz se aquele pedaço foi **medido** pelo motor (sólido) ou **estimado** pela régua do modelo (hachurado).

Esperado × retrabalho. Do total de US\$ 2,25, **US\$ 0,35 (16%) era esperado** e **US\$ 1,90 (84%) é retrabalho** — o mesmo backlog custaria **×6,4 menos** se todo pacote passasse de primeira. O múltiplo aqui é em **dinheiro**; o da Tabela 1 é em **contagem de reprovações**, e os dois não têm de coincidir (pacote que reprova muito com modelo barato pesa pouco em dólar, e vice-versa).

Pacotes que mais gastaram insistindo:

pacote	sprint	chamadas	esperado (US) retrabalho(US)	múltiplo	
P02	002	14	0,021	0,293	15,1x
P04	004	10	0,021	0,198	10,6x
P09	002	9	0,021	0,180	9,7x
P03	002	9	0,021	0,179	9,6x
P04	002	9	0,021	0,176	9,5x
P01	004	8	0,021	0,151	8,3x

Em chamadas: **17** foram a tentativa de acertar de primeira e **86** foram retrabalho.

O que é medido e o que é estimado. O motor só começou a gravar tokens em 28/09 (P-10, lendo o rodapé do Codex): **13 das 103 chamadas (12.6%)** têm token medido. A parte **sólida** da barra é essa medição; a **hachurada** são as chamadas sem medição, estimadas pela régua de tokens por chamada do modelo — a média **medida no próprio motor** para aquele modelo/esforço (5 modelo(s)) e, só para o que o motor nunca viu, a prévia do A/B de 28/09 (4 modelo(s)). Chamada sem régua nenhuma usa a **mediana** das medidas (53,911 tokens). Nada aqui vem de tabela de preço de terceiro.

O preço é o da sua assinatura: US\$ 20/mês = 4 blocos semanais de 100% → **US\$ 0,05 por ponto da janela semanal**; a régua medida é 118.096 tokens por ponto → **US\$ 0,423 por milhão de tokens**. Pela janela de 5h a leitura daria US\$ 0,37/Mtok (as duas estão no relatório de eficiência; a semanal é a que limita).

Total estimado: US\$ 2,25 para as 103 chamadas do Codex — sendo **US\$ 0,29 de token medido** e o resto estimativa. Os pacotes mais caros: **P02** (sprint 002) US\$ 0,314; **P04** (sprint 004) US\$ 0,219; **P09** (sprint 002) US\$ 0,201. Da sprint 001 aparece só o **T15**: os outros 14 pacotes dela são registro retroativo, sem chamada de API — e a única chamada do T15 não tem token medido, então o valor dela é estimativa da régua, não medição.

Objetivos dos pacotes (todas as sprints planejadas até agora)

Uma linha por pacote, com o objetivo como está no `dag.json` de cada sprint — lido do **plano**, não escrito à mão. É o mapa do que cada pacote do backlog pedia, para ler as tabelas acima sabendo o que estava sendo pedido em cada um.

sprint	pacote	objetivo (título do pacote no plano)
001	T01	Detectar agentes de código instalados
001	T02	Definir schemas de Sprint e de task
001	T03	Implementar store de estado em SQLite
001	T04	Implementar gerente de worktrees Git
001	T05	Implementar adaptador do Codex
001	T06	Implementar adaptador do Antigravity/AGY
001	T07	Implementar isolamento de execução (sandbox)
001	T08	Implementar runner de testes determinístico
001	T09	Implementar revisor independente entre agentes
001	T10	Implementar lógica de retry e recuperação
001	T11	Implementar Fila de Ação Humana (HAQ)
001	T12	Implementar branch de integração do Sprint
001	T13	Implementar geração do relatório do Sprint
001	T14	Criar projeto-fixture ponta a ponta
001	T15	Executar teste de aceitação autônomo
002	P01	Criar autodev/planner.py com os tipos do plano e validação de schema
002	P02	Criar autodev/plan_prompt.py com o prompt de planejamento
002	P03	Parsear a resposta do agente de forma tolerante
002	P04	Validar o plano contra o DAG real e contra critério vago
002	P05	Escrever o sprint planejado em disco
002	P06	Invocar o agente em modo planejamento
002	P07	Adicionar o comando autodev plan na CLI
002	P08	Provar a aceitação: do prompt ao sprint executável
002	P09	Registrar a rastreabilidade do prompt ao plano
002	P10	Documentar o planejador e fechar a documentação
003	P01	Detectar colisão de arquivo entre tasks do plano
003	P02	Barrar colisão na mesma onda no validador do motor
003	P03	Relatório de impacto do plano em módulo próprio
003	P04	Comando autodev prever: impacto do plano antes de rodar
003	P05	Portão de aprovação humana do plano
003	P06	Aceitação ponta a ponta do portão do plano
003	P07	Documentar o portão do plano e o checklist derivado do D-16
004	P01	Restaurar a hierarquia de seções do README
004	P02	Fazer o teste de documentação isolar a seção do Planejador
004	P03	Tirar do README o que não bate com o código
004	P04	Comando de teste nos critérios tem de rodar nesta máquina

Arquivos gerados e proveniência

arquivo	o que é
REPORT-TENTATIVAS-CODEX.md	este relatório
report/histograma-tentativas.png	gráfico 1
report/distribuicao-tentativas.png	gráfico 2
report/custo-por-pacote.png	gráfico 3 (custo estimado: medido × estimado)
report/dados.json	agregação crua usada no texto e nos gráficos
report/gerar_relatorio_tentativas.py	gera os três a partir de <code>.autodev/state.db</code>
report/relatorio-tentativas.html / .pdf	HTML autocontido e PDF A4

Reproduzir:

```
cd ~/Code/Coding_Machine
~/hermes/cache/scratch/venv_report/bin/python report/gerar_relatorio_tentativas.py
pandoc REPORT-TENTATIVAS-CODEX.md -o report/relatorio-tentativas.html --standalone \
  --embed-resources --resource-path=.:report --css=report/estilo-relatorio.css \
  --metadata lang=pt-BR
chromium --headless=new --disable-gpu --no-sandbox --user-data-dir=/tmp/chrome-pdf \
  --virtual-time-budget=30000 --no-pdf-header-footer \
  --print-to-pdf="$PWD/report/relatorio-tentativas.pdf" \
  "file://$PWD/report/relatorio-tentativas.html"
```

O venv `~/hermes/cache/scratch/venv_report` existe só para o `matplotlib` (o venv do projeto não tem gráficos) e é descartável: `uv venv + uv pip install matplotlib`.